

Traitement et analyse des données hydrologiques

TP 1 : Diagnostic d'une série hydrologique

Arsène KIEMA

25 juin 2026

Table des matières

1	Objectif du TP	3
2	1. Mise en situation	3
3	2. Création du jeu de données	4
3.1	Questions	5
4	3. Vérifier la structure des données	5
4.1	Ce que fait R	5
4.2	Questions	6
5	4. Afficher le début et la fin de la série	6
5.1	Questions	6
6	5. Résumé statistique rapide	6
6.1	Ce que fait R	7
6.2	Questions	7
7	6. Calculer le nombre total d'observations	7
7.1	Questions	7
8	7. Identifier les données manquantes	8
8.1	Ce que fait R	8
8.2	Questions	8
9	8. Calculer le taux de lacune	8
9.1	Questions	9

10	9. Rechercher les valeurs physiquement impossibles	9
10.1	Questions	10
11	10. Visualiser la chronique	10
11.1	Ce que fait l'hydrologue	11
11.2	Questions	11
12	11. Ajouter les points observés	11
12.1	Questions	12
13	12. Ajouter une ligne de référence à zéro	12
13.1	Questions	12
14	13. Histogramme des débits	13
14.1	Ce que fait R	13
14.2	Questions	13
15	14. Boxplot des débits	13
15.1	Ce que fait R	14
15.2	Questions	14
16	15. Comprendre les quartiles	14
16.1	Ce que fait R	15
16.2	Questions	15
17	16. Bornes de détection des valeurs aberrantes	15
17.1	Questions	16
18	17. Identifier les valeurs aberrantes par la méthode des quartiles	16
18.1	Questions	17
19	18. Comparer valeurs négatives et valeurs aberrantes	17
19.1	Questions	17
20	19. Créer une colonne de statut	18
20.1	Questions	18
21	20. Compter les statuts	19
21.1	Questions	19
22	21. Graphique avec statuts	19
22.1	Questions	20
23	22. Tableau de diagnostic final	20

24	23. Conclusion hydrologique attendue	21
24.1	Exemple de formulation	21
25	24. Travail à rendre	21
26	25. Ce que doit retenir l'hydrologue	22
27	26. Transition vers le TP suivant	22

1 Objectif du TP

Ce TP vise à apprendre à réaliser le **diagnostic initial d'une chronique hydrologique** à l'aide de R.

À la fin du TP, l'étudiant sera capable de :

- créer ou importer une chronique hydrologique ;
- vérifier la structure des données ;
- identifier les données manquantes ;
- calculer le taux de lacune ;
- produire des statistiques descriptives simples ;
- visualiser une série temporelle ;
- utiliser un boxplot pour détecter les valeurs aberrantes ;
- identifier les valeurs aberrantes à partir des quartiles ;
- formuler un diagnostic hydrologique.

! Principe du TP

Les codes R sont entièrement fournis.

Vous devez les copier dans R ou RStudio, les exécuter, observer les résultats, puis répondre aux questions.

2 1. Mise en situation

Vous travaillez dans un service hydrologique national.

Votre responsable vous remet une chronique journalière de débit et vous demande :

Avant d'utiliser cette série pour produire un bulletin hydrologique, pouvez-vous vérifier si elle est exploitable ?

Votre travail consiste donc à réaliser un **diagnostic hydrologique initial**.

 Question centrale du TP

La série est-elle directement exploitable pour une analyse hydrologique?

3 2. Création du jeu de données

Dans ce TP, nous utilisons une chronique journalière fictive mais réaliste de débit sur environ trois mois.

La série contient volontairement :

- des valeurs normales;
- des données manquantes;
- des valeurs négatives impossibles;
- des valeurs très élevées à vérifier;
- une période de crue.

```
# =====  
# Création d'une chronique journalière de débit  
# =====  
  
# Création d'une séquence de dates journalières  
dates <- seq.Date(  
  from = as.Date("2026-06-01"),  
  to   = as.Date("2026-08-31"),  
  by   = "day"  
)  
  
debits <- c(  
  180, 182, 179, 185, 188, 190, 187, 192, 195, 198,  
  200, 205, 210, 208, 215, 220, 225, 230, 235, 240,  
  245, 250, NA, 255, 260, 265, 270, 275, 280, 285,  
  290, 295, 300, 310, 320, 335, 350, 370, 390, 410,  
  430, 460, 500, 550, 600, 680, 760, 850, 940, 1030,  
  1120, 1210, 1300, 1380, 1450, 1500, 1480, 1420, 1350, 1280,  
  1180, 1050, 920, 800, 700, 620, 560, 500, 460, 420,  
  390, NA, 360, 340, 320, 300, -25, 280, 270, 260,  
  250, 240, 230, 220, 210, 205, NA, 195, 190, 185,
```

```

2500, -10
)

# Création du tableau de données
# data.frame() assemble les colonnes Date et Debit dans un même tableau

debit <- data.frame(
  Date = dates,
  Debit = debits
)

# Afficher le tableau

debit

```

3.1 Questions

1. Quelle est la période couverte par la chronique ?
 2. Combien d'observations contient la série ?
 3. Observez-vous déjà des anomalies dans le tableau ?
 4. Pourquoi est-il préférable de travailler sur une série de plusieurs semaines plutôt que sur quelques jours seulement ?
-

4 3. Vérifier la structure des données

Avant toute analyse, il faut vérifier que les colonnes sont correctement reconnues par R.

```

# str() affiche la structure du tableau
str(debit)

```

4.1 Ce que fait R

La fonction `str()` permet de vérifier rapidement :

- le nombre d'observations ;
- le nombre de variables ;
- le type de chaque variable ;
- quelques valeurs de chaque colonne.

4.2 Questions

1. Quel est le type de la variable Date ?
 2. Quel est le type de la variable Debit ?
 3. Pourquoi est-il important que les débits soient reconnus comme des valeurs numériques ?
 4. Pourquoi est-il important que les dates soient reconnues comme des dates ?
-

5 4. Afficher le début et la fin de la série

Les fonctions `head()` et `tail()` permettent d'inspecter rapidement le début et la fin du tableau.

```
# head() affiche les premières lignes du tableau
```

```
head(debit)
```

```
# tail() affiche les dernières lignes du tableau
```

```
tail(debit)
```

5.1 Questions

1. Quelle est la première date de la série ?
 2. Quelle est la dernière date de la série ?
 3. Les dernières valeurs semblent-elles normales ?
 4. Pourquoi faut-il toujours inspecter visuellement le début et la fin d'un jeu de données ?
-

6 5. Résumé statistique rapide

Le résumé statistique donne une première idée de la distribution des valeurs.

```
# summary() fournit un résumé statistique rapide
```

```
summary(debit)
```

6.1 Ce que fait R

La fonction `summary()` donne une vue d'ensemble de la série.

Elle permet de repérer rapidement :

- les valeurs minimales;
- les valeurs maximales;
- les valeurs manquantes;
- les ordres de grandeur.

6.2 Questions

1. Quelle est la valeur minimale du débit ?
 2. Cette valeur est-elle physiquement possible ?
 3. Quelle est la valeur maximale du débit ?
 4. Cette valeur paraît-elle plausible ?
 5. Combien de valeurs manquantes sont signalées ?
 6. Que peut-on déjà conclure sur la qualité de la série ?
-

7 6. Calculer le nombre total d'observations

```
# nrow() compte le nombre de lignes du tableau  
  
n_total <- nrow(debit)  
  
# Afficher le nombre total d'observations  
  
n_total
```

7.1 Questions

1. Combien d'observations journalières contient la série ?
 2. Ce nombre correspond-il au nombre de jours entre le 1er juin et le 31 août 2026 ?
-

8 7. Identifier les données manquantes

```
# is.na() permet d'identifier les valeurs manquantes
```

```
is.na(debit$Debit)
```

```
# Extraire les lignes où le débit est manquant
```

```
donnees_manquantes <- debit[is.na(debit$Debit), ]
```

```
# Afficher les données manquantes
```

```
donnees_manquantes
```

8.1 Ce que fait R

La fonction `is.na()` ne modifie pas les données.

Elle indique simplement quelles observations sont manquantes.

8.2 Questions

1. Combien de données manquantes observe-t-on ?
 2. À quelles dates se trouvent les données manquantes ?
 3. Les lacunes sont-elles isolées ou groupées ?
 4. Peut-on remplacer automatiquement ces valeurs par zéro ?
-

9 8. Calculer le taux de lacune

Le taux de lacune mesure la proportion de données manquantes dans la série.

$$TL = \frac{N_{manq}}{N_{att}} \times 100$$

où :

- TL : taux de lacune ;
- N_{manq} : nombre de données manquantes ;
- N_{att} : nombre total d'observations attendues.

```
# Compter le nombre de valeurs manquantes
# sum() additionne les TRUE produits par is.na()
# Dans R, TRUE est compté comme 1 et FALSE comme 0
```

```
n_manquant <- sum(is.na(debit$Debit))
```

```
# Calculer le taux de lacune
```

```
taux_lacune <- n_manquant / n_total * 100
```

```
# Afficher le résultat
```

```
taux_lacune
```

```
# Afficher le résultat arrondi à une décimale
```

```
round(taux_lacune, 1)
```

9.1 Questions

1. Quel est le taux de lacune ?
2. Ce taux est-il faible, moyen ou élevé ?
3. La série est-elle très lacunaire ?
4. Le taux de lacune suffit-il à juger la qualité d'une série ?

À retenir

Un taux de lacune faible ne signifie pas nécessairement que la série est de bonne qualité. Il faut également rechercher les valeurs impossibles, les valeurs aberrantes et les incohérences hydrologiques.

10 9. Rechercher les valeurs physiquement impossibles

Un débit ne peut pas être négatif.

Les valeurs négatives doivent donc être automatiquement signalées.

```
# Sélectionner les lignes où le débit est inférieur à zéro
# Ces valeurs sont physiquement impossibles en hydrologie

valeurs_negatives <- debit[debit$Debit < 0, ]

# Afficher les valeurs négatives détectées

valeurs_negatives
```

10.1 Questions

1. Combien de valeurs négatives sont détectées ?
2. À quelles dates apparaissent-elles ?
3. Pourquoi ces valeurs sont-elles impossibles ?
4. Quel statut peut-on attribuer à ces valeurs ?
5. Faut-il les supprimer directement ?

Attention

Une valeur physiquement impossible doit être signalée, vérifiée et documentée.
Elle ne doit pas être corrigée sans justification.

11 10. Visualiser la chronique

La visualisation graphique est une étape essentielle du diagnostic.

```
# Tracer la chronique journalière de débit
# plot() permet de produire un graphique simple
# type = "l" trace une ligne
# xlab et ylab définissent les titres des axes
# main définit le titre du graphique

plot(
  debit$Date,
  debit$Debit,
```

```

type = "l",
xlab = "Date",
ylab = "Débit (m³/s)",
main = "Chronique journalière de débit"
)

```

11.1 Ce que fait l'hydrologue

L'hydrologue observe :

- la tendance générale;
- les pics;
- les ruptures;
- les valeurs isolées;
- les périodes sans données;
- les valeurs physiquement impossibles.

11.2 Questions

1. Quelle est la forme générale de la chronique ?
 2. Observe-t-on une période de montée des débits ?
 3. Observe-t-on une période de décrue ?
 4. Les valeurs aberrantes sont-elles visibles ?
 5. Pourquoi le graphique est-il indispensable avant toute analyse ?
-

12 11. Ajouter les points observés

Il est souvent utile d'afficher à la fois la ligne et les points.

```

# Tracer la chronique avec des points
# type = "o" signifie que les points et la ligne sont affichés
# pch = 16 indique des points pleins

plot(
  debit$Date,
  debit$Debit,
  type = "o",

```

```

pch = 16,
xlab = "Date",
ylab = "Débit (m³/s)",
main = "Chronique de débit avec points observés"
)

```

12.1 Questions

1. Les anomalies sont-elles plus visibles avec les points ?
 2. Quelles observations méritent une vérification ?
 3. Quelle période semble correspondre à une crue ?
-

13 12. Ajouter une ligne de référence à zéro

```

# Représenter la chronique de débit

plot(
  debit$Date,
  debit$Debit,
  type = "o",
  pch = 16,
  xlab = "Date",
  ylab = "Débit (m³/s)",
  main = "Contrôle visuel des valeurs négatives"
)

# Ajouter une ligne horizontale au niveau zéro
# Les valeurs situées sous cette ligne sont physiquement impossibles

abline(h = 0, lty = 2)

```

13.1 Questions

1. Quelles valeurs sont situées sous la ligne zéro ?
2. Pourquoi cette ligne est-elle utile ?

3. Quel type de contrôle représente cette vérification ?

14 13. Histogramme des débits

L'histogramme permet d'observer la distribution des valeurs.

```
# hist() permet de représenter la distribution des débits
# breaks indique le nombre approximatif de classes

hist(
  debit$Debit,
  breaks = 15,
  xlab = "Débit (m³/s)",
  main = "Histogramme des débits journaliers"
)
```

14.1 Ce que fait R

La fonction `hist()` regroupe les valeurs en classes et indique le nombre d'observations dans chaque classe.

14.2 Questions

1. Les débits sont-ils répartis de manière symétrique ?
 2. Observe-t-on des valeurs très élevées ?
 3. L'histogramme permet-il de détecter les valeurs extrêmes ?
 4. Pourquoi les séries hydrologiques sont-elles souvent asymétriques ?
-

15 14. Boxplot des débits

Le boxplot, ou boîte à moustaches, permet d'identifier visuellement les valeurs potentiellement aberrantes.

```
# boxplot() construit une boîte à moustaches
# Cette représentation permet de détecter les valeurs extrêmes

boxplot(
  debit$Debit,
  ylab = "Débit (m³/s)",
  main = "Boxplot des débits journaliers"
)
```

15.1 Ce que fait R

La fonction `boxplot()` représente :

- la médiane;
- le premier quartile;
- le troisième quartile;
- les moustaches;
- les points situés au-delà des moustaches.

Ces points sont considérés comme des valeurs potentiellement aberrantes.

15.2 Questions

1. Observe-t-on des points en dehors des moustaches ?
 2. Combien de valeurs semblent potentiellement aberrantes ?
 3. Ces valeurs sont-elles forcément fausses ?
 4. Pourquoi faut-il interpréter les valeurs aberrantes avec prudence ?
-

16 15. Comprendre les quartiles

Le boxplot repose sur les quartiles.

```
# Calculer le premier quartile Q1
# 25 % des observations sont inférieures ou égales à Q1

Q1 <- quantile(debit$Debit, 0.25, na.rm = TRUE)
```

```

# Calculer le troisième quartile Q3
# 75 % des observations sont inférieures ou égales à Q3

Q3 <- quantile(debit$Debit, 0.75, na.rm = TRUE)

# Calculer l'intervalle interquartile
# IQR mesure la dispersion des 50 % centrales de la série

IQR_debit <- Q3 - Q1

# Afficher les résultats

Q1
Q3
IQR_debit

```

16.1 Ce que fait R

La fonction `quantile()` permet de calculer les valeurs qui divisent la série en proportions données.

16.2 Questions

1. Quelle est la valeur de Q1 ?
2. Quelle est la valeur de Q3 ?
3. Que représente l'intervalle interquartile ?
4. Pourquoi l'IQR est-il utile pour détecter les valeurs aberrantes ?

17 16. Bornes de détection des valeurs aberrantes

La méthode classique du boxplot considère comme potentiellement aberrantes les valeurs situées en dehors des bornes :

$$Borne_{inf} = Q1 - 1.5 \times IQR$$

$$Borne_{sup} = Q3 + 1.5 \times IQR$$

```

# Calculer la borne inférieure
# Les valeurs inférieures à cette borne sont considérées comme suspectes

borne_inf <- Q1 - 1.5 * IQR_debit

# Calculer la borne supérieure
# Les valeurs supérieures à cette borne sont considérées comme suspectes

borne_sup <- Q3 + 1.5 * IQR_debit

# Afficher les bornes

borne_inf
borne_sup

```

17.1 Questions

1. Quelle est la borne inférieure ?
 2. Quelle est la borne supérieure ?
 3. Une valeur négative sera-t-elle détectée ?
 4. Une valeur très élevée sera-t-elle détectée ?
-

18 17. Identifier les valeurs aberrantes par la méthode des quartiles

```

# Sélectionner les valeurs situées en dehors des bornes
# Une valeur est suspecte si elle est inférieure à la borne inférieure
# ou supérieure à la borne supérieure

valeurs_aberrantes <- debit[
  debit$Debit < borne_inf | debit$Debit > borne_sup,
]

# Afficher les valeurs aberrantes détectées

valeurs_aberrantes

```


18.1 Questions

1. Combien de valeurs aberrantes sont détectées ?
2. À quelles dates apparaissent-elles ?
3. S'agit-il uniquement de valeurs très élevées ?
4. Une valeur négative peut-elle aussi être détectée comme aberrante ?
5. Ces valeurs doivent-elles être automatiquement supprimées ?

! Message clé

Une valeur détectée comme aberrante par une méthode statistique doit être vérifiée hydrologiquement avant toute correction.

19 18. Comparer valeurs négatives et valeurs aberrantes

```
# Afficher les valeurs négatives
```

```
valeurs_negatives
```

```
# Afficher les valeurs aberrantes détectées par les quartiles
```

```
valeurs_aberrantes
```

19.1 Questions

1. Les valeurs négatives sont-elles aussi détectées comme aberrantes ?
2. Les valeurs aberrantes sont-elles toutes physiquement impossibles ?
3. Quelle est la différence entre une valeur impossible et une valeur suspecte ?
4. Pourquoi faut-il combiner plusieurs contrôles ?

20 19. Créer une colonne de statut

On peut créer une colonne qui attribue un statut simple à chaque observation.

```
# Créer une colonne Statut avec la valeur par défaut "Valide"
# rep() répète le mot "Valide" autant de fois qu'il y a de lignes

debit$Statut <- rep("Valide", nrow(debit))

# Marquer les données manquantes

debit$Statut[is.na(debit$Debit)] <- "Manquante"

# Marquer les valeurs négatives

debit$Statut[debit$Debit < 0] <- "Impossible"

# Marquer les valeurs aberrantes
# On évite de modifier les données manquantes avec la condition !is.na()

debit$Statut[
  !is.na(debit$Debit) &
  (debit$Debit < borne_inf | debit$Debit > borne_sup)
] <- "Suspecte"

# Afficher le tableau avec les statuts

debit
```

20.1 Questions

1. Quels statuts apparaissent dans la colonne Statut ?
 2. Combien d'observations sont marquées comme Manquante ?
 3. Combien d'observations sont marquées comme Impossible ?
 4. Combien d'observations sont marquées comme Suspecte ?
 5. Une valeur suspecte est-elle nécessairement fausse ?
-

21 20. Compter les statuts

```
# table() permet de compter le nombre d'observations par catégorie  
table(debit$Statut)
```

21.1 Questions

1. Combien d'observations sont valides ?
 2. Combien d'observations nécessitent une vérification ?
 3. La série est-elle directement exploitable ?
-

22 21. Graphique avec statuts

On peut représenter la chronique en distinguant les statuts.

```
# Définir une couleur pour chaque statut  
# Cette étape permet de visualiser les anomalies sur le graphique  
  
couleurs <- ifelse(  
  debit$Statut == "Valide", "black",  
  ifelse(  
    debit$Statut == "Manquante", "grey",  
    ifelse(  
      debit$Statut == "Impossible", "red",  
      "orange"  
    )  
  )  
)  
  
# Tracer la chronique  
  
plot(  
  debit$Date,  
  debit$Debit,  
  type = "o",
```

```

pch = 16,
col = couleurs,
xlab = "Date",
ylab = "Débit (m³/s)",
main = "Diagnostic de la chronique de débit"
)

# Ajouter la ligne zéro

abline(h = 0, lty = 2)

# Ajouter une légende

legend(
  "topleft",
  legend = c("Valide", "Manquante", "Impossible", "Suspecte"),
  col = c("black", "grey", "red", "orange"),
  pch = 16,
  bty = "n"
)

```

22.1 Questions

1. Les anomalies sont-elles faciles à localiser ?
2. Quel statut domine la série ?
3. Quelles observations doivent être vérifiées en priorité ?
4. Le graphique est-il plus utile que le tableau seul ?

23 22. Tableau de diagnostic final

Complétez le tableau suivant à partir de vos résultats.

Élément diagnostiqué	Résultat
Nombre total d'observations	
Nombre de données manquantes	
Taux de lacune	
Nombre de valeurs impossibles	

Élément diagnostiqué	Résultat
Nombre de valeurs suspectes	
Méthode utilisée pour les valeurs aberrantes	
Série directement exploitable ?	

24 23. Conclusion hydrologique attendue

Rédigez une conclusion courte en vous appuyant sur vos résultats.

Votre conclusion doit préciser :

- la période couverte ;
- le nombre d'observations ;
- le taux de lacune ;
- les valeurs impossibles détectées ;
- les valeurs suspectes détectées ;
- l'exploitabilité de la série.

24.1 Exemple de formulation

La chronique couvre la période du 01 juin au 31 août 2026.

Elle comprend 92 observations journalières.

Le taux de lacune est faible, mais plusieurs anomalies ont été détectées.

Deux valeurs négatives sont physiquement impossibles.

La méthode des quartiles met également en évidence plusieurs valeurs potentiellement aberrantes.

La série n'est donc pas directement exploitable sans vérification et traitement préalable.

25 24. Travail à rendre

Chaque étudiant ou groupe doit remettre :

1. le tableau de diagnostic final ;
2. le graphique de la chronique avec les statuts ;

3. le boxplot;
 4. la liste des valeurs aberrantes détectées;
 5. une conclusion hydrologique de 5 à 10 lignes.
-

26 25. Ce que doit retenir l'hydrologue

À retenir

Avant toute analyse hydrologique, il faut toujours :

- inspecter la structure des données;
 - vérifier les données manquantes;
 - calculer le taux de lacune;
 - rechercher les valeurs physiquement impossibles;
 - visualiser la chronique;
 - examiner la distribution des valeurs;
 - utiliser le boxplot pour repérer les valeurs suspectes;
 - interpréter les anomalies dans leur contexte hydrologique;
 - ne jamais supprimer une valeur aberrante sans justification.
-

27 26. Transition vers le TP suivant

Dans ce TP, nous avons réalisé le diagnostic initial d'une chronique hydrologique.

Nous avons identifié :

- des données manquantes;
- des valeurs impossibles;
- des valeurs suspectes;
- des observations à vérifier.

Le TP suivant portera sur les **méthodes de reconstitution des données manquantes** et la comparaison de plusieurs approches :

- moyenne;
- médiane;
- valeur précédente;

- interpolation linéaire;
- régression.