

Traitement et analyse des données hydrologiques

TP 1 : Diagnostic d'une série hydrologique (Partie I)

Arsène KIEMA

26 juin 2026

Table des matières

1	Objectif du TP	2
2	1. Mise en situation	2
3	2. Création du jeu de données	3
3.1	Questions	4
4	3. Vérifier la structure des données	4
4.1	Ce que fait R	5
4.2	Questions	5
5	4. Afficher le début et la fin de la série	5
5.1	Questions	5
6	5. Résumé statistique rapide	6
6.1	Ce que fait R	6
6.2	Questions	6
7	6. Calculer le nombre total d'observations	6
7.1	Questions	7
8	7. Identifier les données manquantes	7
8.1	Ce que fait R	7
8.2	Questions	7
9	8. Calculer le taux de lacune	8
9.1	Questions	8

10	9. Rechercher les valeurs physiquement impossibles	9
10.1	Questions	9
11	10. Visualiser la chronique	10
11.1	Ce que fait l'hydrologue	10
11.2	Questions	10
12	11. Ajouter les points observés	11
12.1	Questions	11
13	12. Ajouter une ligne de référence à zéro	11
13.1	Questions	12

1 Objectif du TP

Ce TP vise à apprendre à réaliser le **diagnostic initial d'une chronique hydrologique** à l'aide de R.

À la fin du TP, l'étudiant sera capable de :

- créer ou importer une chronique hydrologique ;
- vérifier la structure des données ;
- identifier les données manquantes ;
- calculer le taux de lacune ;
- produire des statistiques descriptives simples ;
- visualiser une série temporelle ;
- utiliser un boxplot pour détecter les valeurs aberrantes ;
- identifier les valeurs aberrantes à partir des quartiles ;
- formuler un diagnostic hydrologique.

! Principe du TP

Les codes R sont entièrement fournis.

Vous devez les copier dans R ou RStudio, les exécuter, observer les résultats, puis répondre aux questions.

2 1. Mise en situation

Vous travaillez dans un service hydrologique national.

Votre responsable vous remet une chronique journalière de débit et vous demande :

Avant d'utiliser cette série pour produire un bulletin hydrologique, pouvez-vous vérifier si elle est exploitable ?

Votre travail consiste donc à réaliser un **diagnostic hydrologique initial**.

 Question centrale du TP

La série est-elle directement exploitable pour une analyse hydrologique ?

3 2. Création du jeu de données

Dans ce TP, nous utilisons une chronique journalière fictive mais réaliste de débit sur environ trois mois.

La série contient volontairement :

- des valeurs normales ;
- des données manquantes ;
- des valeurs négatives impossibles ;
- des valeurs très élevées à vérifier ;
- une période de crue.

```
# =====  
# Création d'une chronique journalière de débit  
# =====  
  
# Création d'une séquence de dates journalières  
dates <- seq.Date(  
  from = as.Date("2026-06-01"),  
  to   = as.Date("2026-08-31"),  
  by   = "day"  
)  
  
debits <- c(  
  180, 182, 179, 185, 188, 190, 187, 192, 195, 198,  
  200, 205, 210, 208, 215, 220, 225, 230, 235, 240,  
  245, 250, NA, 255, 260, 265, 270, 275, 280, 285,  
  290, 295, 300, 310, 320, 335, 350, 370, 390, 410,
```

```

430, 460, 500, 550, 600, 680, 760, 850, 940, 1030,
1120, 1210, 1300, 1380, 1450, 1500, 1480, 1420, 1350, 1280,
1180, 1050, 920, 800, 700, 620, 560, 500, 460, 420,
390, NA, 360, 340, 320, 300, -25, 280, 270, 260,
250, 240, 230, 220, 210, 205, NA, 195, 190, 185,
2500, -10
)

# Création du tableau de données
# data.frame() assemble les colonnes Date et Debit dans un même tableau

debit <- data.frame(
  Date = dates,
  Debit = debits
)

# Afficher le tableau

debit

```

3.1 Questions

1. Quelle est la période couverte par la chronique ?
 2. Combien d'observations contient la série ?
 3. Observez-vous déjà des anomalies dans le tableau ?
 4. Pourquoi est-il préférable de travailler sur une série de plusieurs semaines plutôt que sur quelques jours seulement ?
-

4 3. Vérifier la structure des données

Avant toute analyse, il faut vérifier que les colonnes sont correctement reconnues par R.

```

# str() affiche la structure du tableau
str(debit)

```

4.1 Ce que fait R

La fonction `str()` permet de vérifier rapidement :

- le nombre d'observations ;
- le nombre de variables ;
- le type de chaque variable ;
- quelques valeurs de chaque colonne.

4.2 Questions

1. Quel est le type de la variable `Date` ?
 2. Quel est le type de la variable `Debit` ?
 3. Pourquoi est-il important que les débits soient reconnus comme des valeurs numériques ?
 4. Pourquoi est-il important que les dates soient reconnues comme des dates ?
-

5 4. Afficher le début et la fin de la série

Les fonctions `head()` et `tail()` permettent d'inspecter rapidement le début et la fin du tableau.

```
# head() affiche les premières lignes du tableau
```

```
head(debit)
```

```
# tail() affiche les dernières lignes du tableau
```

```
tail(debit)
```

5.1 Questions

1. Quelle est la première date de la série ?
 2. Quelle est la dernière date de la série ?
 3. Les dernières valeurs semblent-elles normales ?
 4. Pourquoi faut-il toujours inspecter visuellement le début et la fin d'un jeu de données ?
-

6 5. Résumé statistique rapide

Le résumé statistique donne une première idée de la distribution des valeurs.

```
# summary() fournit un résumé statistique rapide  
summary(debit)
```

6.1 Ce que fait R

La fonction `summary()` donne une vue d'ensemble de la série.

Elle permet de repérer rapidement :

- les valeurs minimales;
- les valeurs maximales;
- les valeurs manquantes;
- les ordres de grandeur.

6.2 Questions

1. Quelle est la valeur minimale du débit ?
 2. Cette valeur est-elle physiquement possible ?
 3. Quelle est la valeur maximale du débit ?
 4. Cette valeur paraît-elle plausible ?
 5. Combien de valeurs manquantes sont signalées ?
 6. Que peut-on déjà conclure sur la qualité de la série ?
-

7 6. Calculer le nombre total d'observations

```
# nrow() compte le nombre de lignes du tableau  
  
n_total <- nrow(debit)  
  
# Afficher le nombre total d'observations  
  
n_total
```

7.1 Questions

1. Combien d'observations journalières contient la série ?
 2. Ce nombre correspond-il au nombre de jours entre le 1er juin et le 31 août 2026 ?
-

8 7. Identifier les données manquantes

```
# is.na() permet d'identifier les valeurs manquantes  
  
is.na(debit$Debit)
```

```
# Extraire les lignes où le débit est manquant  
  
donnees_manquantes <- debit[is.na(debit$Debit), ]  
  
# Afficher les données manquantes  
  
donnees_manquantes
```

8.1 Ce que fait R

La fonction `is.na()` ne modifie pas les données.

Elle indique simplement quelles observations sont manquantes.

8.2 Questions

1. Combien de données manquantes observe-t-on ?
 2. À quelles dates se trouvent les données manquantes ?
 3. Les lacunes sont-elles isolées ou groupées ?
 4. Peut-on remplacer automatiquement ces valeurs par zéro ?
-

9 8. Calculer le taux de lacune

Le taux de lacune mesure la proportion de données manquantes dans la série.

$$TL = \frac{N_{manq}}{N_{att}} \times 100$$

où :

- TL : taux de lacune ;
- N_{manq} : nombre de données manquantes ;
- N_{att} : nombre total d'observations attendues.

```
# Compter le nombre de valeurs manquantes  
# sum() additionne les TRUE produits par is.na()  
# Dans R, TRUE est compté comme 1 et FALSE comme 0
```

```
n_manquant <- sum(is.na(debit$Debit))
```

```
# Calculer le taux de lacune
```

```
taux_lacune <- n_manquant / n_total * 100
```

```
# Afficher le résultat
```

```
taux_lacune
```

```
# Afficher le résultat arrondi à une décimale
```

```
round(taux_lacune, 1)
```

9.1 Questions

1. Quel est le taux de lacune ?
2. Ce taux est-il faible, moyen ou élevé ?
3. La série est-elle très lacunaire ?
4. Le taux de lacune suffit-il à juger la qualité d'une série ?

À retenir

Un taux de lacune faible ne signifie pas nécessairement que la série est de bonne qualité.
Il faut également rechercher les valeurs impossibles, les valeurs aberrantes et les incohérences hydrologiques.

10 9. Rechercher les valeurs physiquement impossibles

Un débit ne peut pas être négatif.

Les valeurs négatives doivent donc être automatiquement signalées.

```
# Sélectionner les lignes où le débit est inférieur à zéro
# Ces valeurs sont physiquement impossibles en hydrologie

valeurs_negatives <- debit[debit$Debit < 0, ]

# Afficher les valeurs négatives détectées

valeurs_negatives
```

10.1 Questions

1. Combien de valeurs négatives sont détectées ?
2. À quelles dates apparaissent-elles ?
3. Pourquoi ces valeurs sont-elles impossibles ?
4. Quel statut peut-on attribuer à ces valeurs ?
5. Faut-il les supprimer directement ?

Attention

Une valeur physiquement impossible doit être signalée, vérifiée et documentée.
Elle ne doit pas être corrigée sans justification.

11 10. Visualiser la chronique

La visualisation graphique est une étape essentielle du diagnostic.

```
# Tracer la chronique journalière de débit
# plot() permet de produire un graphique simple
# type = "l" trace une ligne
# xlab et ylab définissent les titres des axes
# main définit le titre du graphique

plot(
  debit$Date,
  debit$Debit,
  type = "l",
  xlab = "Date",
  ylab = "Débit (m³/s)",
  main = "Chronique journalière de débit"
)
```

11.1 Ce que fait l'hydrologue

L'hydrologue observe :

- la tendance générale;
- les pics;
- les ruptures;
- les valeurs isolées;
- les périodes sans données;
- les valeurs physiquement impossibles.

11.2 Questions

1. Quelle est la forme générale de la chronique ?
 2. Observe-t-on une période de montée des débits ?
 3. Observe-t-on une période de décrue ?
 4. Les valeurs aberrantes sont-elles visibles ?
 5. Pourquoi le graphique est-il indispensable avant toute analyse ?
-

12 11. Ajouter les points observés

Il est souvent utile d'afficher à la fois la ligne et les points.

```
# Tracer la chronique avec des points
# type = "o" signifie que les points et la ligne sont affichés
# pch = 16 indique des points pleins

plot(
  debit$Date,
  debit$Debit,
  type = "o",
  pch = 16,
  xlab = "Date",
  ylab = "Débit (m³/s)",
  main = "Chronique de débit avec points observés"
)
```

12.1 Questions

1. Les anomalies sont-elles plus visibles avec les points ?
 2. Quelles observations méritent une vérification ?
 3. Quelle période semble correspondre à une crue ?
-

13 12. Ajouter une ligne de référence à zéro

```
# Représenter la chronique de débit

plot(
  debit$Date,
  debit$Debit,
  type = "o",
  pch = 16,
  xlab = "Date",
  ylab = "Débit (m³/s)",
  main = "Contrôle visuel des valeurs négatives"
```

```
)  
  
# Ajouter une ligne horizontale au niveau zéro  
# Les valeurs situées sous cette ligne sont physiquement impossibles  
  
abline(h = 0, lty = 2)
```

13.1 Questions

1. Quelles valeurs sont situées sous la ligne zéro ?
2. Pourquoi cette ligne est-elle utile ?
3. Quel type de contrôle représente cette vérification ?