

Traitement et analyse des données hydrologiques

TP 1 : Diagnostic d'une série hydrologique

Arsène KIEMA

26 juin 2026

Table des matières

1	14. Boxplot des débits	2
1.1	Ce que fait R	2
1.2	Questions	2
2	15. Comprendre les quartiles	3
2.1	Ce que fait R	3
2.2	Questions	3
3	16. Bornes de détection des valeurs aberrantes	4
3.1	Questions	4
4	17. Identifier les valeurs aberrantes par la méthode des quartiles	4
4.1	Questions	5
5	18. Comparer valeurs négatives et valeurs aberrantes	5
5.1	Questions	6
6	19. Créer une colonne de statut	6
6.1	Questions	7
7	20. Compter les statuts	7
7.1	Questions	7
8	21. Graphique avec statuts	7
8.1	Questions	8
9	22. Tableau de diagnostic final	9

10	23. Conclusion hydrologique attendue	9
10.1	Exemple de formulation	9
11	24. Travail à rendre	10
12	25. Ce que doit retenir l'hydrologue	10
13	26. Transition vers le TP suivant	10

1 14. Boxplot des débits

Le boxplot, ou boîte à moustaches, permet d'identifier visuellement les valeurs potentiellement aberrantes.

```
# boxplot() construit une boîte à moustaches
# Cette représentation permet de détecter les valeurs extrêmes

boxplot(
  debit$Debit,
  ylab = "Débit (m³/s)",
  main = "Boxplot des débits journaliers"
)
```

1.1 Ce que fait R

La fonction `boxplot()` représente :

- la médiane;
- le premier quartile;
- le troisième quartile;
- les moustaches;
- les points situés au-delà des moustaches.

Ces points sont considérés comme des valeurs potentiellement aberrantes.

1.2 Questions

1. Observe-t-on des points en dehors des moustaches ?
2. Combien de valeurs semblent potentiellement aberrantes ?
3. Ces valeurs sont-elles forcément fausses ?
4. Pourquoi faut-il interpréter les valeurs aberrantes avec prudence ?

2 15. Comprendre les quartiles

Le boxplot repose sur les quartiles.

```
# Calculer le premier quartile Q1
# 25 % des observations sont inférieures ou égales à Q1

Q1 <- quantile(debit$Debit, 0.25, na.rm = TRUE)

# Calculer le troisième quartile Q3
# 75 % des observations sont inférieures ou égales à Q3

Q3 <- quantile(debit$Debit, 0.75, na.rm = TRUE)

# Calculer l'intervalle interquartile
# IQR mesure la dispersion des 50 % centrales de la série

IQR_debit <- Q3 - Q1

# Afficher les résultats

Q1
Q3
IQR_debit
```

2.1 Ce que fait R

La fonction `quantile()` permet de calculer les valeurs qui divisent la série en proportions données.

2.2 Questions

1. Quelle est la valeur de Q1 ?
 2. Quelle est la valeur de Q3 ?
 3. Que représente l'intervalle interquartile ?
 4. Pourquoi l'IQR est-il utile pour détecter les valeurs aberrantes ?
-

3 16. Bornes de détection des valeurs aberrantes

La méthode classique du boxplot considère comme potentiellement aberrantes les valeurs situées en dehors des bornes :

$$Borne_{inf} = Q1 - 1.5 \times IQR$$

$$Borne_{sup} = Q3 + 1.5 \times IQR$$

```
# Calculer la borne inférieure
# Les valeurs inférieures à cette borne sont considérées comme suspectes

borne_inf <- Q1 - 1.5 * IQR_debit

# Calculer la borne supérieure
# Les valeurs supérieures à cette borne sont considérées comme suspectes

borne_sup <- Q3 + 1.5 * IQR_debit

# Afficher les bornes

borne_inf
borne_sup
```

3.1 Questions

1. Quelle est la borne inférieure ?
 2. Quelle est la borne supérieure ?
 3. Une valeur négative sera-t-elle détectée ?
 4. Une valeur très élevée sera-t-elle détectée ?
-

4 17. Identifier les valeurs aberrantes par la méthode des quartiles

```
# Sélectionner les valeurs situées en dehors des bornes
# Une valeur est suspecte si elle est inférieure à la borne inférieure
# ou supérieure à la borne supérieure

valeurs_aberrantes <- debit[
  debit$Debit < borne_inf | debit$Debit > borne_sup,
]

# Afficher les valeurs aberrantes détectées

valeurs_aberrantes
```

4.1 Questions

1. Combien de valeurs aberrantes sont détectées ?
2. À quelles dates apparaissent-elles ?
3. S'agit-il uniquement de valeurs très élevées ?
4. Une valeur négative peut-elle aussi être détectée comme aberrante ?
5. Ces valeurs doivent-elles être automatiquement supprimées ?

! Message clé

Une valeur détectée comme aberrante par une méthode statistique doit être vérifiée hydrologiquement avant toute correction.

5 18. Comparer valeurs négatives et valeurs aberrantes

```
# Afficher les valeurs négatives
```

```
valeurs_negatives
```

```
# Afficher les valeurs aberrantes détectées par les quartiles
```

```
valeurs_aberrantes
```

5.1 Questions

1. Les valeurs négatives sont-elles aussi détectées comme aberrantes ?
 2. Les valeurs aberrantes sont-elles toutes physiquement impossibles ?
 3. Quelle est la différence entre une valeur impossible et une valeur suspecte ?
 4. Pourquoi faut-il combiner plusieurs contrôles ?
-

6 19. Créer une colonne de statut

On peut créer une colonne qui attribue un statut simple à chaque observation.

```
# Créer une colonne Statut avec la valeur par défaut "Valide"
# rep() répète le mot "Valide" autant de fois qu'il y a de lignes

debit$Statut <- rep("Valide", nrow(debit))

# Marquer les données manquantes

debit$Statut[is.na(debit$Debit)] <- "Manquante"

# Marquer les valeurs négatives

debit$Statut[debit$Debit < 0] <- "Impossible"

# Marquer les valeurs aberrantes
# On évite de modifier les données manquantes avec la condition !is.na()

debit$Statut[
  !is.na(debit$Debit) &
  (debit$Debit < borne_inf | debit$Debit > borne_sup)
] <- "Suspecte"

# Afficher le tableau avec les statuts

debit
```

6.1 Questions

1. Quels statuts apparaissent dans la colonne Statut ?
 2. Combien d'observations sont marquées comme Manquante ?
 3. Combien d'observations sont marquées comme Impossible ?
 4. Combien d'observations sont marquées comme Suspecte ?
 5. Une valeur suspecte est-elle nécessairement fausse ?
-

7 20. Compter les statuts

```
# table() permet de compter le nombre d'observations par catégorie  
table(debit$Statut)
```

7.1 Questions

1. Combien d'observations sont valides ?
 2. Combien d'observations nécessitent une vérification ?
 3. La série est-elle directement exploitable ?
-

8 21. Graphique avec statuts

On peut représenter la chronique en distinguant les statuts.

```
# Définir une couleur pour chaque statut  
# Cette étape permet de visualiser les anomalies sur le graphique  
  
couleurs <- ifelse(  
  debit$Statut == "Valide", "black",  
  ifelse(  
    debit$Statut == "Manquante", "grey",  
    ifelse(  
      debit$Statut == "Impossible", "red",
```

```

        "orange"
    )
)
)

# Tracer la chronique

plot(
  debit$Date,
  debit$Debit,
  type = "o",
  pch = 16,
  col = couleurs,
  xlab = "Date",
  ylab = "Débit (m³/s)",
  main = "Diagnostic de la chronique de débit"
)

# Ajouter la ligne zéro

abline(h = 0, lty = 2)

# Ajouter une légende

legend(
  "topleft",
  legend = c("Valide", "Manquante", "Impossible", "Suspecte"),
  col = c("black", "grey", "red", "orange"),
  pch = 16,
  bty = "n"
)

```

8.1 Questions

1. Les anomalies sont-elles faciles à localiser ?
2. Quel statut domine la série ?
3. Quelles observations doivent être vérifiées en priorité ?
4. Le graphique est-il plus utile que le tableau seul ?

9 22. Tableau de diagnostic final

Complétez le tableau suivant à partir de vos résultats.

Élément diagnostiqué	Résultat
Nombre total d'observations	
Nombre de données manquantes	
Taux de lacune	
Nombre de valeurs impossibles	
Nombre de valeurs suspectes	
Méthode utilisée pour les valeurs aberrantes	
Série directement exploitable ?	

10 23. Conclusion hydrologique attendue

Rédigez une conclusion courte en vous appuyant sur vos résultats.

Votre conclusion doit préciser :

- la période couverte ;
- le nombre d'observations ;
- le taux de lacune ;
- les valeurs impossibles détectées ;
- les valeurs suspectes détectées ;
- l'exploitabilité de la série.

10.1 Exemple de formulation

La chronique couvre la période du 01 juin au 31 août 2026.

Elle comprend 92 observations journalières.

Le taux de lacune est faible, mais plusieurs anomalies ont été détectées.

Deux valeurs négatives sont physiquement impossibles.

La méthode des quartiles met également en évidence plusieurs valeurs potentiellement aberrantes.

La série n'est donc pas directement exploitable sans vérification et traitement préalable.

11 24. Travail à rendre

Chaque étudiant ou groupe doit remettre :

1. le tableau de diagnostic final ;
 2. le graphique de la chronique avec les statuts ;
 3. le boxplot ;
 4. la liste des valeurs aberrantes détectées ;
 5. une conclusion hydrologique de 5 à 10 lignes.
-

12 25. Ce que doit retenir l'hydrologue

À retenir

Avant toute analyse hydrologique, il faut toujours :

- inspecter la structure des données ;
 - vérifier les données manquantes ;
 - calculer le taux de lacune ;
 - rechercher les valeurs physiquement impossibles ;
 - visualiser la chronique ;
 - examiner la distribution des valeurs ;
 - utiliser le boxplot pour repérer les valeurs suspectes ;
 - interpréter les anomalies dans leur contexte hydrologique ;
 - ne jamais supprimer une valeur aberrante sans justification.
-

13 26. Transition vers le TP suivant

Dans ce TP, nous avons réalisé le diagnostic initial d'une chronique hydrologique.

Nous avons identifié :

- des données manquantes ;
- des valeurs impossibles ;
- des valeurs suspectes ;
- des observations à vérifier.

Le TP suivant portera sur les **méthodes de reconstitution des données manquantes** et la comparaison de plusieurs approches :

- moyenne ;
- médiane ;
- valeur précédente ;
- interpolation linéaire ;
- régression.